


programa lineal:  $c, x \in \mathbb{R}^n, A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m, m > n$

$$\begin{array}{ll} \min c^T x \\ \text{s.a. } Ax \leq b \\ x \geq 0 \end{array}$$

ejemplo:  $\min -x_1 - 3x_2$   
 s.a.  $x_1 + x_2 \leq 6$   
 $-x_1 + 2x_2 \leq 8$   
 $x_1, x_2 \geq 0$




### Teorema de Farkas:

Uno y sólo uno de los 2 sistemas siguientes tiene una solución: 1)  $c^T p > 0$  2)  $A^T \lambda = 0$   $\lambda \geq 0$



Interpretación geométrica:  $A = \begin{bmatrix} a_1^T \\ \vdots \\ a_m^T \end{bmatrix} \in \mathbb{R}^{m \times n}$  entonces:

Sistema 1 tiene solución: el semiespacio abierto  $\{p : c^T p > 0\}$  intersección con el cono  $\{p : A^T p \leq 0\}$  no es vacío;


$$\{p : c^T p > 0\}$$




$$\{p : A^T p \leq 0\} = \{p : a_1^T p \leq 0, a_2^T p \leq 0, \dots, a_m^T p \leq 0\}$$



Intersección:



Sistema 2 tiene solución si y solo si  $C$  pertenece al cono generado por los renglones de  $A$ :



Obs: Si un sistema tiene solución (si no tiene solución el otro no tiene y viceversa)

Condiciones de KKT para el problema

$$\begin{array}{ll} \min_{\mathbf{x}} & \mathbf{c}^T \mathbf{x} \\ \text{s.a.} & \left. \begin{array}{l} \mathbf{A}\mathbf{x} \leq \mathbf{b} \\ -\mathbf{x} \leq \mathbf{0} \end{array} \right\} \quad \left. \begin{array}{l} \min_{\mathbf{x}} \mathbf{c}^T \mathbf{x} \\ \text{s.a. } \begin{bmatrix} \mathbf{A} \\ \mathbf{I} \end{bmatrix} \mathbf{x} \leq \begin{bmatrix} \mathbf{b} \\ \mathbf{0} \end{bmatrix} \end{array} \right\} \quad \left. \begin{array}{l} \min_{\tilde{\mathbf{x}}} \mathbf{c}^T \tilde{\mathbf{x}} \\ \text{s.a. } \tilde{\mathbf{A}}\tilde{\mathbf{x}} \leq \tilde{\mathbf{b}} \in \mathbb{R}^m \end{array} \right\} \end{array}$$

$$L(x, \lambda) = \mathbf{c}^T \mathbf{x} + \lambda^T (\tilde{\mathbf{A}}\mathbf{x} - \tilde{\mathbf{b}}) = \mathbf{c}^T \mathbf{x} + \lambda_1^T (\mathbf{A}\mathbf{x} - \mathbf{b}) + \lambda_2^T (-\mathbf{x})$$

$$\downarrow \quad \quad \quad \downarrow$$

$$\lambda_1 \in \mathbb{R}^m \quad \quad \quad \lambda_2 \in \mathbb{R}^n$$

condiciones de KKT:  $\mathbf{x}$  mínimo ent.  $\exists \lambda_1, \lambda_2$  que satisfacen:

$$\nabla_{\mathbf{x}} L(x, \lambda_1, \lambda_2) = \mathbf{0} = \mathbf{c} + \mathbf{A}^T \lambda_1 - \lambda_2 \rightarrow$$

$$\lambda_1^T (\mathbf{A}\mathbf{x} - \mathbf{b}) = \mathbf{0} \quad \text{holgura complementaria}$$

$$\lambda_2^T (-\mathbf{x}) = \mathbf{0}$$

$$\mathbf{A}\mathbf{x} - \mathbf{b} \leq \mathbf{0}$$

$$-\mathbf{x} \leq \mathbf{0}$$

$$\lambda \geq \mathbf{0}$$

$$\nabla f(\mathbf{x}) = - \sum_{i=1}^m \lambda_1(i) \mathbf{a}_i - \sum_{i=1}^n \lambda_2(i) \mathbf{e}_i$$

gradiente de  $f$  es combinación lineal

$\mathbf{h} = \mathbf{a}_i, -\mathbf{e}_i$ . De hecho por holgura

complementaria es combinación lineal

únicamente de las restricciones activas

(pues las inactivas,  $f_i(x) < 0$

tienen  $\lambda_i = 0$  para alguna  $i = 1, \dots, n$ )

Problema dual:  $\max -b^T \lambda$ ,

$$\text{s.a. } c + A^T \lambda_1 - \lambda_2 = 0$$

$$\lambda_1 \geq 0$$

$$\lambda_2 \geq 0$$

Relación entre condiciones KKT y el teorema de Farkas?


Si  $x$  no es mínimo entonces  $\exists$  dirección de descenso  $\Delta x$ . Supóngase que  $A \Delta x \geq 0$  entonces:

$$1) \nabla f(x)^T \Delta x = c^T \Delta x < 0 \quad (\text{dirección de descenso}) \quad 2) A \Delta x \geq 0 \quad (\text{suposición})$$

$$\therefore c^T p > 0 \quad \text{tiene solución (tomando } p = -\Delta x) \quad \text{y por Teorema de Farkas} \quad A^T \lambda = c \\ A p \leq 0 \quad \lambda \geq 0$$

no tiene solución (gradiente de  $f$  objetivo no es combinación lineal de cada gradiente de las restricciones activas)

En el ejemplo:  $\min -x_1 - 3x_2$   
 s.a.  $x_1 + x_2 \leq 6$  se tiene:  
 $-x_1 + 2x_2 \leq 8$   
 $x_1, x_2 \geq 0$



$(6,0)$  no es mínimo de  $f$  :  
 $c$  no es combinación lineal del gradiente de las restricciones activas :


$$c = \begin{pmatrix} -1 \\ -3 \end{pmatrix} \neq \lambda_1(1)\begin{pmatrix} 1 \\ 1 \end{pmatrix} + \lambda_2(1)\begin{pmatrix} 1 \\ -2 \end{pmatrix}, \quad \lambda_1(1) \geq 0 \quad \text{pero sí } \lambda_2(1) \geq 0 \quad \text{pero } c^T p > 0, \quad A p \leq 0 \quad \text{tiene solución.} \therefore \exists \text{ dirección de descenso}$$

Mismo análisis para los puntos  $(0,0), (0,4)$ . Para el mínimo  $(1/3, 14/3)$  las restricciones activas

son  $x_1 + x_2 \leq 6$   
 $-x_1 + 2x_2 \leq 8$  y  $c$  es combinación lineal del gradiente de las restricciones activas ( $A^T \lambda = c$  si tiene solución)  
 $\lambda \geq 0$

$$C = \begin{pmatrix} -1 \\ -3 \end{pmatrix} = \lambda_1 \begin{pmatrix} 1 \\ 1 \end{pmatrix} + \lambda_2 \begin{pmatrix} -1 \\ 2 \end{pmatrix}, \lambda_1 = \frac{5}{3}, \lambda_2 = \frac{2}{3}. \text{ El problema } C^T p > 0, A p \leq 0 \text{ no tiene solución.}$$

$\therefore \nexists$  dirección de descenso.



Para problemas  $\min f_0(x)$  con  $f_0$  y  $h_i$  convexas y diferenciables  $\forall i = 1, \dots, p$   
 sujeto a:  $h_i(x) = 0$   
 $i = 1, \dots, p$

si  $x$  no es mínimo entonces  $\exists \Delta x$  dirección de descenso y suponemos  $\Delta x$  satisface

$\nabla h_i(x)^T \Delta x = 0 \quad \forall i = 1, \dots, p$  entonces reescribiendo  $\nabla h_i(x)^T \Delta x = 0 \quad \forall i = 1, \dots, p$

(como  $\nabla h_i(x)^T \Delta x \leq 0 \quad \forall i = 1, \dots, p$  se tiene: 1)  $\nabla f_0(x)^T \Delta x < 0$  2)  $\nabla h_i(x)^T \Delta x \geq 0$   
 $\nabla h_i(x)^T \Delta x \geq 0$       dirección de descenso       $-\nabla h_i(x)^T \Delta x \geq 0$   
 $\forall i = 1, \dots, p$        $\forall i = 1, \dots, p$

Suposición

$\therefore \nabla f_0(x)^T p > 0$  tiene solución  $\left( \text{tomando } p = -\Delta x \right)$  y por Teorema de Farkas  $A^T \lambda = \nabla f_0(x)$   
 $A p \leq 0$        $\lambda \geq 0$   
 $y A = \begin{bmatrix} \nabla h_1(x) \\ \vdots \\ \nabla h_p(x) \end{bmatrix}$

no tiene solución (gradiente de  $f_0$  no es combinación lineal de cada gradiente de las restricciones activas)

Asimismo,  $x$  mínimo local de  $f$   $\nabla f(x)^T p > 0$  no tiene solución y por Teorema de Farkas  $A^T p \leq 0$

$A^T \lambda = \nabla f(x)$  tiene solución ( $\text{gradiente de } f_0 \text{ es combinación lineal de los gradientes de las restricciones activas}$ )

(Mismo análisis se realiza para  $\begin{array}{l} \min f_0(x) \\ \text{sujeto a: } f_i(x) \leq 0 \\ \quad \forall i=1, \dots, m \end{array}$ ) ... Entonces:

$\min f_0(x)$   
sujeto a:  $f_i(x) \leq 0 \quad \forall i=1, \dots, m$   
 $h_i(x)=0 \quad \forall i=1, \dots, p$  se define la Lagrangiana como una función

$L: \mathbb{R}^n \times \mathbb{R}^m \times \mathbb{R}^p \rightarrow \mathbb{R}$  asociada al problema anterior como:

$$L(x, \lambda, \nu) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p \nu_i h_i(x) \text{ con } \text{dom } L = D \times \mathbb{R}^m \times \mathbb{R}^p.$$

- Notas:
- $\lambda_i$  se llama multiplicador de Lagrange asociado con la  $i$ -ésima restricción de desigualdad  $f_i(x) \leq 0$ .
  - $\nu_i$  se llama multiplicador de Lagrange asociado con la  $i$ -ésima restricción de igualdad  $h_i(x) = 0$ .
  - Los vectores  $\lambda, \nu$  son llamados variables duales o vectores de multiplicadores de Lagrange asociados con el problema anterior.

## Condiciones de Karush-Kuhn-Tucker (KKT) de optimidad.

Supóngase que  $f_0, f_1, \dots, f_m, h_1, h_2, \dots, h_p$  son diferenciables con dominios abiertos

### Condiciones KKT para problemas no convexos.

Sean  $x^*, (\lambda^*, \nu^*)$  un par primal-dual de puntos óptimos con duality gap cero.

Como  $x^*$  minimiza  $L(x, \lambda^*, \nu^*)$  sobre  $x$  entonces:

$$\nabla_x L(x^*, \lambda^*, \nu^*) = \nabla f_0(x^*) + \sum_{i=1}^m \lambda_i^* \nabla f_i(x^*) + \sum_{i=1}^p \nu_i^* \nabla h_i(x^*) = 0$$

y por factibilidad y holgura complementaria:  $f_i(x^*) \leq 0 \quad \forall i=1, \dots, m$

$$\lambda_i^* \geq 0 \quad \forall i=1, \dots, m$$

$$h_i(x^*) = 0 \quad \forall i=1, \dots, p$$

$$\lambda_i^* f_i(x^*) = 0 \quad \forall i=1, \dots, m$$

Comentario: las 5 condiciones anteriores son llamadas las condiciones de optimidad de Karush-Kuhn-Tucker que se satisfacen para cualquier problema de optimización con función objetivo y funciones restricción diferenciables evaluadas en un par primal dual de puntos óptimos en el que se cumple la dualidad fuerte. Obsérvese que son condiciones necesarias.

## Condiciones KKT para problemas convexos.

Si el problema primal es convexo, esto es,  $f_i$  son convexas  $\forall i=0,1,\dots,m$   $h_i$  son afín  $\forall i=1,\dots,p$  entonces las condiciones KKT de optimalidad son suficientes para puntos primal-dual óptimos:

Sean  $\tilde{x}, \tilde{\lambda}, \tilde{\nu}$  puntos que satisfacen las condiciones KKT de optimalidad:

$$\nabla_{\tilde{x}} L(\tilde{x}, \tilde{\lambda}, \tilde{\nu}) = f_0(\tilde{x}) + \sum_{i=1}^m \tilde{\lambda}_i \nabla f_i(\tilde{x}) + \sum_{i=1}^p \tilde{\nu}_i \nabla h_i(\tilde{x}) = 0$$

$$f_i(\tilde{x}) \leq 0 \quad \forall i=1,2,\dots,m \quad h_i(\tilde{x}) = 0 \quad \forall i=1,2,\dots,p$$

$$\tilde{\lambda}_i \geq 0 \quad \forall i=1,2,\dots,m \quad \tilde{\lambda}_i f_i(\tilde{x}) = 0 \quad \forall i=1,2,\dots,m$$

Entonces como se tiene un problema convexo,  $\tilde{\lambda}_i > 0 \quad \forall i=1,2,\dots,p$

y  $\tilde{x}, \tilde{\lambda}, \tilde{\nu}$  satisfacen  $\nabla_{\tilde{x}} L(\tilde{x}, \tilde{\lambda}, \tilde{\nu}) = 0$  resulta:

.)  $L(x, \lambda, \nu)$  es convexa      .)  $\tilde{x}$  es mínimo de  $L(x, \lambda, \nu)$  y es primal factible.

$$\therefore g(\tilde{\lambda}, \tilde{\nu}) = L(\tilde{x}, \tilde{\lambda}, \tilde{\nu}) = f_0(\tilde{x}) + \sum_{i=1}^m \tilde{\lambda}_i f_i(\tilde{x}) + \sum_{i=1}^p \tilde{\nu}_i h_i(\tilde{x}) = f_0(\tilde{x})$$

por factibilidad primal y holgura complementaria ↘

por lo tanto,  $\tilde{x}, (\tilde{\lambda}, \tilde{\nu})$  tienen duality gap igual a cero y son puntos primal dual óptimos.

En resumen:

1) Para cualquier problema de optimización convexa con funciones objetivo y de restricciones diferenciables en el que una pareja de puntos primal-dual satisfacen las condiciones KKT de optimalidad, son óptimos para el problema primal y dual y tienen duality gap igual a cero.

2) Si un problema de optimización convexa con funciones objetivo y de restricción diferenciables satisface la condición de Slater entonces las condiciones de KKT proveen condiciones necesarias y suficientes para optimalidad de puntos primal-dual.

La condición de Slater implica que la duality gap es cero y el óptimo dual se alcanza, entonces  $x$  es punto óptimo primal si y solo si existe  $(\lambda, \nu)$  tal que junto con  $x$  satisfacen las condiciones KKT de optimalidad.

Comentario: en algunos casos especiales es posible resolver las condiciones KKT de manera analítica y en general muchos algoritmos de optimización resultan o pueden interpretarse como métodos que resuelven las condiciones de KKT.

La condición  $\lambda_i^* f_i(x^*) = 0$  se llama holgura complementaria y se cumple para cualquier punto óptimo primal  $x^*$  y punto óptimo dual  $(\lambda^*, \nu^*)$  bajo dualidad fuerte.

La condición de holgura complementaria se escribe como:  $\lambda_i^* > 0 \Rightarrow f_i(x^*) = 0$

o equivalentemente:  $f_i(x^*) \leq 0 \Rightarrow \lambda_i^* = 0$  si  $\lambda_i^*$  es el  $i$ -ésimo multiplicador

de Lagrange es positivo entonces la  $i$ -ésima función restricción de desigualdad es activa.

Nota 4.5.3:  $\min f(x)$  Suposiciones:  
s.a  $Ax=b$

1)  $f: \mathbb{R}^n \rightarrow \mathbb{R}$  convexa y  $C^2$  en su dom $f$

2)  $A \in \mathbb{R}^{p \times n}$  rank(A) =  $p < n$

3)  $\exists x^*$  óptimo,  $p^*$  valor óptimo

Condiciones KKT:  $x^* \in \text{dom } f$  es óptimo si y sólo si:

$$\exists v \in \mathbb{R}^p \text{ tal que: } Ax^* = b, \begin{array}{c} \nabla f(x^*) + A^T v^* = 0 \\ \text{factibilidad} \\ \text{primal} \end{array}, \begin{array}{c} \perp \\ \perp \\ \text{factibilidad} \\ \text{dual} \end{array}$$

2 condiciones y una idea basada en aproximación de 2º orden para extender el método de Newton a problemas de la forma  $\min f(x)$   
s.a  $Ax=b$ :

Condiciones:

1)  $x^{(0)}$  punto inicial debe ser factible:  $x^{(0)} \in \text{dom } f$  y  $Ax^{(0)} = b$

2) El paso de Newton,  $\Delta x_{\text{nt}}$ , debe modificarse de modo que satisfaga las restricciones

Para esto la idea consiste en:

$$\min \hat{f}(x) \rightarrow \min \hat{f}(x+v) \quad \text{con } \hat{f}'(x+v) = f'(x) + \nabla^2 f(x)^T v + \frac{1}{2} v^T \nabla^2 f(x) v$$

s.a.  $Ax=b$       s.a.  $A(x+v)=b$

y como  $f$  es convexa este problema es de minimización cuadrática con restricciones de igualdad

y tiene solución  $(\Delta x_{\text{nt}}, w)$  que satisfacen al sistema:  $\begin{bmatrix} \nabla^2 f(x) & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} \Delta x_{\text{nt}} \\ w \end{bmatrix} = \begin{bmatrix} -\nabla f(x) \\ 0 \end{bmatrix}$  el cual

resulta de las condiciones de KKT y del hecho que como  $Ax=b$  y  $A(x+v)=b$

entonces  $Av=0$  | en este caso  $v=\Delta x_{\text{nt}}$  y  $w$  es variable dual asociada

$$\begin{array}{l} \hookrightarrow \min x^T P x + q^T x + r \quad P \in S_+^n, \Delta \in \mathbb{R}^{P \times n} \text{ entonces:} \\ \text{s.a. } Ax = b \end{array}$$

$$\text{cond KKT: } \begin{bmatrix} P & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} x^* \\ v^* \end{bmatrix} = \begin{bmatrix} -q \\ b \end{bmatrix}$$

Obs

- El paso de Newton  $\Delta_{x_{nt}}$  está definido para puntos en los que la matriz KKT es no singular
- $x + \Delta_{x_{nt}}$  estimación de  $x^*$ ,  $v$  estimación de  $v^*$
- Decremento de Newton:  $\lambda(x) = \left\| \Delta_{x_{nt}} \right\|_2 = (\Delta_{x_{nt}}^T \nabla^2 f(x) \Delta_{x_{nt}})^{1/2}$ 
  - Ayuda al backtracking pues:  $\nabla^2 f(x)^T \Delta_{x_{nt}} = -\lambda^2(x)$
  - Ayuda al criterio de paro:  $\frac{\lambda^2(x)}{2} \leq \text{tolerancia}$ ,  $\lambda^2(x)$  estima  $f(x) - p^*$

### Método de Newton con restricciones de igualdad

Dados un punto inicial  $x \in \text{dom} f$  con  $Ax = b$  y una tolerancia  $\varepsilon > 0$ .

Repetir:

1. Calcular el paso y decremento de Newton  $\Delta_{x_{nt}}, \lambda(x)$ .

2. Criterio de paro: terminar método si  $\frac{\lambda^2(x)}{2} \leq \varepsilon$ .

3. Búsqueda de línea: Elegir tamaño de paso por método de backtracking line search.

4. Actualizar:  $x + t \Delta_{x_{nt}}$ .